

AgroSearch - Motor de Busca Inteligente

Relatório Técnico de Recuperação de Informação e NLP (Revisado)

Instituição: UNIPE - Centro Universitário de João Pessoa

Professor: Me. Ricardo Roberto de Lima

Auxílio: Antigravity (Gemini 3.8 Flash)

Disciplina: Tendências em Ciência da Computação

Equipe: João Gabriel de Araújo Falcão e Perilo de Oliveira Vianna Sobrinho

1. ARQUITETURA DO SISTEMA E CÓDIGO FONTE

O sistema **AgroSearch** é uma aplicação interativa em Python desenvolvida com Streamlit (`desafio.py`) para busca e ranqueamento de documentos em formato PDF e TXT. O processamento segue a arquitetura de Processamento de Linguagem Natural (NLP) e o cálculo direto de TF-IDF:

- Extração e Normalização (`utils.py` & `desafio.py`):** O texto é extraído das páginas do PDF via `PdfReader`. Os tokens são identificados com a expressão regular `\b\w+\b`, convertidos para caixa baixa e desprovidos de acentuação usando `unicodedata.normalize('NFD')`. Opcionalmente, são aplicados o filtro de `STOPWORDS` e a redução de sufixos morfológicos através de função própria de *stemming*.
- Índice Invertido em Memória:** É construído um dicionário (`defaultdict(list)`) mapeando cada termo limpo aos IDs dos documentos em que ocorre (`Doc1` a `DocN`).
- Motor Léxico TF-IDF (Fórmulas do Código):** Frequência Relativa do Termo:

$$TF(t, d) = freq(t, d) / total_termos(d)$$

Frequência Inversa do Documento (Logaritmo Natural):

$$IDF(t) = \ln(N / DF(t)) \quad (\text{onde } N \text{ é o total de documentos e } DF \text{ a frequência de documentos})$$

- Pontuação e Ordenação de Consultas:** Para uma busca *query*, o sistema extrai os tokens da consulta, calcula a pontuação acumulada por somatório dos pesos TF-IDF e exibe o ranking ordenado de forma decrescente:

$$Score(q, d) = \sum [TF(t, d) \times IDF(t)] \quad (\text{para todo } t \in q \cap d)$$

2. MATRIZ DE RANQUEAMENTO DO ACERVO REAL

Abaixo apresenta-se o resultado verificado da execução do código para o acervo de 5 PDFs de entrada utilizando a consulta "irrigação na soja":

ID Doc	Nome do Arquivo PDF Processado	Ocorrência dos Termos da Query	Rank Final
Doc5	soja_irrigacao_floracao(1).pdf	Contém ambos os termos: "irrigação" e "soja"	1º Lugar
Doc3	Irrigação por Gotejamento...pdf	Contém apenas o termo: "irrigação"	2º Lugar
Doc2	controle_biologico_lagartas...pdf	Contém apenas o termo: "soja"	3º Lugar
Doc4	Lagartas Desfolhadoras na Cultura...pdf	Contém apenas o termo: "soja"	4º Lugar
Doc1	Adubação Verde com Leguminosas...pdf	Nenhum termo encontrado (foco em milho)	5º (Zero)

Análise Qualitativa dos Resultados do Código:

O **Doc5** obtém a primeira colocação no ranking pois combina os dois termos centrais da consulta no contexto reprodutivo da lavoura. O **Doc3** atinge o segundo lugar focado exclusivamente em irrigação por gotejamento, enquanto **Doc2** e **Doc4** disputam posições intermediárias com o termo "soja". O **Doc1** recebe pontuação zero por tratar exclusivamente de adubação verde no milho, demonstrando a precisão da filtragem por TF-IDF.